SmartDigiCat

Manuel d'utilisation

Version 1.0

Du tableau de mesures au modèle prédictif
et aux conditions optimales

Auteur : Komlan NOUKPOAPE

Chaire industrielle – Centrale Lille

26 septembre 2026

Table des matières

Avant-propos **2**

1 SmartDigiCat, un logiciel exécutable **2**
1.1 Ce que signifie « exécutable » . . . 2
1.2 Lancement . . . 3
1.3 Architecture de la fenêtre . . . 3
1.4 La notion de projet . . . 3
1.5 Langue, police et clavier . . . 4
1.6 Formats de données acceptés . . . 4

2 Fonctions des boutons **4**
2.1 Barre supérieure . . . 4
2.2 Barre latérale gauche . . . 5
2.3 Boutons des panneaux . . . 6
2.4 Cases à cocher fréquentes . . . 7

3 Analyses statistiques **7**
3.1 Préparer les données (Edit data) . . . 7
3.2 Vue d'ensemble d'un tableau (Overview stat) . . . 8
3.3 Statistiques descriptives et corrélations (Continuous columns) . . . 8
3.4 Comparaison de groupes (All columns) . . . 8
3.5 Corrélation avec la cible (Plot corr) . . . 9
3.6 Résumés par groupe (Other analysis) . . . 9
3.7 Graphiques d'exploration . . . 9
3.8 Exporter les résultats . . . 10

4 Modèles de régression : de la création à la prédiction **10**
4.1 Les algorithmes disponibles . . . 10
4.2 Vue d'ensemble du parcours . . . 11
4.3 Étape 1 : préparer le projet et les données . . . 11
4.4 Étape 2 : créer une boîte de modèle . . . 11
4.5 Étape 3 : configurer le modèle . . . 11
4.6 Étape 4 : entraîner avec Run . . . 12
4.7 Étape 5 : évaluer le modèle . . . 12
4.8 Étape 6 : prédire de nouvelles expériences . . . 13

5 Optimisation **13**
5.1 Principe de l'optimisation bayésienne . . . 14
5.2 Ouvrir le panneau . . . 15
5.3 Définir le problème (Optimization settings) . . . 15
5.4 Lancer et suivre l'optimisation . . . 15
5.5 Lire le résultat . . . 16
5.6 Exporter et exploiter les points . . . 16

Avant-propos

SmartDigiCat permet à un chimiste ou à un ingénieur de passer, sans écrire de code, d'un tableau de mesures expérimentales à un modèle prédictif, puis à des conditions opératoires optimisées. Ce manuel suit ce cheminement dans l'ordre où l'utilisateur le parcourt.

Public visé. Le manuel s'adresse à des étudiants de master, doctorants et chercheurs en catalyse, génie des procédés ou sciences des données. Il suppose des bases en statistique descriptive. Les notions d'apprentissage automatique et d'optimisation bayésienne sont expliquées lorsqu'elles apparaissent.

Organisation. Le manuel comprend cinq sections, qui correspondent aux grandes étapes d'une étude.

Section	Contenu	Question à laquelle elle répond
1	Le logiciel exécutable	Comment lancer SmartDigiCat et s'y repérer ?
2	Les boutons	À quoi sert chaque bouton ?
3	Les analyses statistiques	Que disent mes données avant toute modélisation ?
4	Les modèles de régression	Comment construire, évaluer et utiliser un modèle ?
5	L'optimisation	Quelles conditions maximisent ma réponse ?

Conventions de lecture.

— Les libellés de l'interface sont écrits en gras et restent en anglais, comme à l'écran : **Run**, **Edit data**, **Save configure**.

— Une suite de clics s'écrit avec une flèche : **Plots** → **Statistical data** → **View stat**.

— La *cible* (ou variable réponse) désigne la grandeur à prédire, par exemple un rendement. Les *features* (ou variables explicatives) sont les grandeurs qui servent à la prédire, par exemple la température ou la pression.

— Les encadrés « Remarque pédagogique » expliquent le sens statistique d'un résultat, et pas seulement la manière de l'obtenir.

1. SmartDigiCat, un logiciel exécutable

SmartDigiCat v1.0 est une application de bureau autonome : on la lance par un double-clic, sans installer Python ni aucune bibliothèque. Elle est issue du projet scientifique SmartDigiCat, qui réunit catalyse, sciences des données et intelligence artificielle, porté par la chaire industrielle de Centrale Lille.

1.1 Ce que signifie « exécutable »

Le programme est écrit en Python, puis « gelé » avec l'outil PyInstaller. Le gel rassemble dans un même paquet l'interpréteur Python, les bibliothèques scientifiques et les ressources graphiques. L'utilisateur reçoit donc un programme prêt à l'emploi.

Composant embarqué	Rôle dans SmartDigiCat
Tkinter et tkmacosx	Interface graphique : fenêtres, boutons, listes
pandas et NumPy	Lecture, filtrage et calcul sur les tableaux de données
scikit-learn et mlxtend	Modèles de régression, validation croisée, sélection des features
SciPy	Tests statistiques et lois de probabilité de l'optimisation
Matplotlib	Tous les graphiques
python-docx et openpyxl	Exports Word et Excel
Dossier `figures`	Icônes des boutons

Remarque pédagogique

Geler un programme garantit la reproductibilité : deux utilisateurs qui ont la même version obtiennent les mêmes résultats, car ils utilisent exactement les mêmes versions de bibliothèques.

1.2 Lancement

1. Copier le dossier de l'application sur le disque, sans séparer l'exécutable de ses ressources.
2. Double-cliquer sur l'exécutable SmartDigiCat. Sur macOS, un premier lancement peut demander une autorisation dans les Réglages de sécurité.
3. La fenêtre principale s'ouvre ; sa barre de titre affiche « SmartDigiCat v1.0 », puis le nom du projet ouvert.

Les calculs longs s'exécutent en arrière-plan : l'interface reste réactive et un bouton d'arrêt  permet de les interrompre.

1.3 Architecture de la fenêtre

La fenêtre principale comporte quatre zones fixes.

Zone	Position	Contenu
Barre supérieure	Haut	Gestion du projet, des données, des modèles et des résultats
Barre latérale	Gauche	Actions sur les modèles, arrêt, capture, export, langue, zoom
Panneau central	Centre	Espace de travail : tableaux, graphiques, réglages
Barre inférieure	Bas	Messages d'état (annulation, rétablissement)

Chaque bouton de la barre supérieure affiche son propre panneau dans le panneau central. Le curseur vertical  de la barre gauche règle le zoom du graphique affiché.

1.4 La notion de projet

Toute étude se déroule dans un *projet*, enregistré dans un fichier JSON. Le projet conserve :

— le chemin du fichier de données et les filtres appliqués ;

— tous les modèles, leur configuration, leurs résultats, leur couleur et leur position ;

— les paramètres et le dernier résultat de l'optimisation ;

— les réglages d'affichage des graphiques.

Trois mécanismes protègent le travail :

— **Sauvegarde automatique** : le projet est enregistré toutes les 5 minutes.

— **Historique** : les 20 dernières actions peuvent être annulées (**Undo**) ou rétablies (**Redo**).

— **Fermeture protégée** : à la fermeture, une boîte propose d'enregistrer, de quitter sans enregistrer ou d'annuler.

1.5 Langue, police et clavier

Le bouton de langue de la barre gauche choisit la langue des instructions, ainsi que la police et sa taille. La touche Entrée valide toutes les boîtes de dialogue et les fenêtres de filtrage ; la touche Échap ferme les boîtes qui le permettent.

1.6 Formats de données acceptés

Le tableau de données est importé au format CSV, Excel (`.xlsx`) ou texte (`.txt`). Il doit contenir une ligne par expérience et une colonne par grandeur. La première ligne porte les noms des colonnes. Les colonnes peuvent être quantitatives (nombres) ou qualitatives (texte, par exemple un nom de catalyseur).

2. Fonctions des boutons

Les boutons se répartissent en deux barres permanentes et en boutons propres à chaque panneau. Les boutons qui nécessitent un projet ouvert restent grisés tant qu'aucun projet n'est ouvert.

2.1 Barre supérieure



Figure 1 – Barre supérieure de SmartDigiCat, de gauche à droite.

Bouton	Fonction	Quand l'utiliser
New	Crée un projet : nom, puis emplacement du fichier JSON	Au début de toute étude
Open	Ouvre un projet JSON existant et restaure données, modèles et résultats	Pour reprendre une étude
Save	Enregistre le projet ouvert	Après une étape importante
Undo	Annule la dernière action (20 niveaux)	Après une erreur de manipulation
Redo	Rétablit l'action annulée	Après un **Undo** de trop
Import data	Importe le tableau de données (CSV, XLSX, TXT)	Juste après la création du projet
Edit data	Ouvre le panneau de préparation des données (section 3.1)	Avant toute analyse
Plots	Ouvre les analyses graphiques et statistiques, et l'optimisation	Exploration (section 3) et optimisation (section 5)
Model	Affiche les boîtes de modèles du projet	Création et configuration (section 4)
Run	Entraîne tous les modèles configurés	Après la configuration
Log	Ouvre le panneau de prédiction et les graphiques des modèles	Après l'entraînement
Help	Affiche ce manuel dans le panneau central, dans la langue choisie	Pour retrouver une explication
Website	Ouvre la page de présentation du projet SmartDigiCat	Pour le contexte scientifique

2.2 Barre latérale gauche

Les cinq premiers boutons agissent sur le modèle sélectionné dans le panneau **Model**.



Figure 2 – Barre latérale gauche. Les icônes claires sont affichées sur fond sombre, comme dans le logiciel.

Bouton	Fonction
Nouveau modèle	Crée une boîte de modèle : nom, puis couleur facultative
Supprimer	Envoie le modèle sélectionné dans la corbeille
Renommer	Change le nom et la couleur de la boîte
Configurer	Ouvre le choix de l'algorithme et ses paramètres
Restaurer	Ouvre la corbeille : restaurer ou supprimer définitivement
Arrêt	Interrompt l'entraînement ou l'optimisation en cours ; actif (fond bleu) seulement pendant une exécution
Capture	Enregistre une image PNG de l'interface
Export des modèles	Exporte la liste des modèles et de leurs résultats en CSV
Langue et police	Choisit la langue des instructions, la police et sa taille
Curseur vertical	Zoom du graphique affiché

Remarque pédagogique

Pendant une exécution, tous les boutons sauf *Arrêt* sont bloqués et un encadré « Execution in progress…» s'affiche. Ce verrouillage empêche de modifier les données pendant qu'un modèle les utilise. On peut déplacer l'encadré à la souris.

2.3 Boutons des panneaux

Les panneaux réutilisent les mêmes boutons, avec toujours le même sens.

Bouton	Panneaux	Fonction
View plot	Graphiques, résultats, optimisation	Trace ou redessine le graphique
Save plot	Graphiques, résultats	Enregistre le graphique en PNG, PDF ou JPEG
View stat	Statistical data	Calcule et affiche les tableaux statistiques
Export stat	Edit data, Statistical data	Exporte les tableaux en Excel, Word ou CSV
Overview stat	Edit data, Log	Tableau récapitulatif de toutes les colonnes
Export clean	Edit data	Exporte les données nettoyées
View & Edit	Edit data	Affiche le tableau et permet sa modification
Save	Filtres, recodage, réglages	Valide la fenêtre ; la touche Entrée a le même effet
Save configure	Configuration d'un modèle	Mémorise la configuration pour les prochains **Run**
Import data	Log, optimisation	Importe un tableau de prédiction ou d'optimisation
Show all	Log	Affiche les données de prédiction
Export pred	Log	Exporte les prédictions
Run optim	Optimisation	Lance l'optimisation
Optimization settings	Optimisation	Ouvre les paramètres de l'optimisation

2.4 Cases à cocher fréquentes

Case	Effet
Define chart title	Ouvre une fenêtre pour le titre et les noms des axes
Detail of model	Affiche le détail des modèles : paramètres, R^2, MSE, nombre d'observations
Model plots (Log)	Affiche les graphiques de tous les modèles entraînés sur tout le panneau
Train data	Ajoute les points d'entraînement au graphique des résultats

3. Analyses statistiques

Avant de modéliser, SmartDigiCat permet de préparer les données, de les décrire, de mesurer les liens entre variables et de les visualiser. Ces analyses sont descriptives : elles résument l'échantillon et orientent le choix des features, sans encore rien prédire.

3.1 Préparer les données (Edit data)

Des données de mauvaise qualité produisent des modèles de mauvaise qualité. Le panneau **Edit data** regroupe les opérations de nettoyage.



Figure 3 – Boutons du panneau **Edit data**.

Opération	Réglages	Effet
Consultation (**View & Edit**)	Colonnes et nombre de lignes à afficher	Affiche et permet de corriger le tableau
Recherche et remplacement de modalité	Colonne, **Search**, **Replace**	Corrige une modalité mal saisie (ex. « Pt/Al2O3 » et « Pt-Al2O3 »)
Renommage (**Rename column**)	Ancien et nouveau nom	Clarifie un nom de colonne
Imputation des manquants, quantitatif	mean, median ou delete	Remplace par la moyenne, la médiane, ou supprime la ligne
Imputation des manquants, qualitatif	modality reference ou delete	Remplace par la modalité la plus fréquente, ou supprime la ligne
Filtrage (**Parameter 1** à **4**)	Colonne, Min, Max	Ne garde que les lignes dans l'intervalle choisi
Recodage (**Categorizing variables**)	Colonnes à catégoriser	Transforme une variable numérique en classes

Remarque pédagogique

La médiane résiste mieux que la moyenne aux valeurs extrêmes. Pour une variable asymétrique, comme une conversion souvent proche de 0 ou de 100 %, l'imputation par la médiane est préférable. Supprimer les lignes incomplètes est le choix le plus sûr quand elles sont peu nombreuses.

3.2 Vue d'ensemble d'un tableau (Overview stat)

Edit data → **Overview stat** produit une fiche d'identité de chaque colonne.

Colonne du tableau	Sens
Characteristics	Nom de la variable
Type	double, integer (quantitatives) ou character (qualitative)
Unique	Nombre de modalités d'une variable qualitative
Modality	Nom de chaque modalité
Missing	Nombre de valeurs manquantes
N	Nombre de valeurs renseignées
mean (SD) / (%)	Moyenne (écart-type) pour une variable quantitative ; pourcentage pour une modalité

Le titre rappelle la taille du tableau (lignes, colonnes). Les variables qualitatives sont surlignées, leurs modalités listées dessous.

3.3 Statistiques descriptives et corrélations (Continuous columns)

Plots → **Statistical data**, choix **Continuous columns**, puis **View stat**. Deux tableaux s'affichent pour toutes les colonnes numériques.



Figure 4 – Boutons du panneau **Statistical data** (sections 3.3 à 3.6).

Tableau des statistiques descriptives. Il donne N, Missing, Mean, Std, Min, Q1, Median, Q3 et Max. Q1 et Q3 sont les premier et troisième quartiles : 50 % des observations se situent entre eux.

Tableau des corrélations de Pearson. Chaque case contient le coefficient r entre deux variables :

$$r_{xy} = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\,\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}} \tag{1}$$

Valeur de r	Lecture
Proche de $+1$	Les deux variables augmentent ensemble, de façon linéaire
Proche de 0	Pas de lien linéaire (un lien non linéaire reste possible)
Proche de -1	Quand l'une augmente, l'autre diminue

Remarque pédagogique

Corrélation n'est pas causalité. Deux features très corrélées entre elles ($|r| > 0{,}9$) apportent presque la même information : en garder une seule stabilise souvent les modèles linéaires.

3.4 Comparaison de groupes (All columns)

Choix **All columns**, puis une colonne qualitative dans **Groupby** (par exemple le catalyseur). Le tableau décrit chaque variable dans chaque groupe et teste si les groupes diffèrent.

Type de variable	Résumé par groupe	Test statistique	Hypothèse nulle H_0
Quantitative	médiane (Q1 ; Q3)	Kruskal-Wallis	Les groupes ont la même distribution
Qualitative	effectif N (%) par modalité	χ^2 d'indépendance	La variable est indépendante du groupe

La statistique de Kruskal-Wallis compare les rangs moyens des groupes, sans supposer de loi normale :

$$H = \frac{12}{N(N+1)} \sum_{g=1}^{k} \frac{R_g^2}{n_g} - 3(N+1) \tag{2}$$

Ici N est l'effectif total, k le nombre de groupes, n_g et R_g l'effectif et la somme des rangs du groupe g.

Lecture de la p-value. Une p-value inférieure à 0,05 conduit à rejeter H_0 au seuil de 5 % : la variable diffère significativement entre les groupes. Le logiciel affiche « <0.001 » pour les très petites valeurs.

3.5 Corrélation avec la cible (Plot corr)

Dans **Statistical data**, choisir une **Target** et des **Features**, puis **Plot corr**. Un diagramme en barres montre le coefficient de Pearson entre la cible et chaque feature. Les barres positives et négatives sont de couleurs différentes. Ce graphique aide à présélectionner les features d'un modèle.

3.6 Résumés par groupe (Other analysis)

Choisir une **Dimension** (colonne de regroupement), une **Method** (min, mean, max ou median) et des paramètres. Le logiciel calcule la statistique demandée pour chaque groupe et trace un diagramme en barres groupées. Exemple : le rendement moyen par catalyseur.

3.7 Graphiques d'exploration



Figure 5 – Menu du bouton **Plots** : les graphiques, les statistiques et l'optimisation.

Graphique (Plots)	Ce qu'il montre	Usage typique
Scatter plot	Nuage de points X–Y, couleur et taille selon d'autres colonnes	Repérer une tendance ou des points aberrants
Box plot	Médiane, quartiles et valeurs extrêmes par groupe	Comparer des distributions
Histogram	Répartition des valeurs d'une variable	Vérifier la forme d'une distribution
plot 3D	Nuage de points dans l'espace X–Y–Z	Visualiser l'effet de deux features sur la cible
Data table	Tableau des données	Contrôle visuel

Chaque graphique accepte un titre et des noms d'axes (**Define chart title**), se zoome avec le curseur de la barre gauche et s'exporte avec **Save plot**.

3.8 Exporter les résultats

Export stat exporte tous les tableaux affichés en une fois : en Excel (une feuille par tableau, mise en forme conservée), en Word (document en paysage) ou en CSV.

4. Modèles de régression : de la création à la prédiction

SmartDigiCat propose huit algorithmes de régression. Un modèle apprend une fonction f telle que $y \approx f(\mathbf{x})$, où y est la cible et $\mathbf{x}$ le vecteur des features. On l'évalue sur des données qu'il n'a pas vues, puis on l'utilise pour prédire de nouvelles expériences.

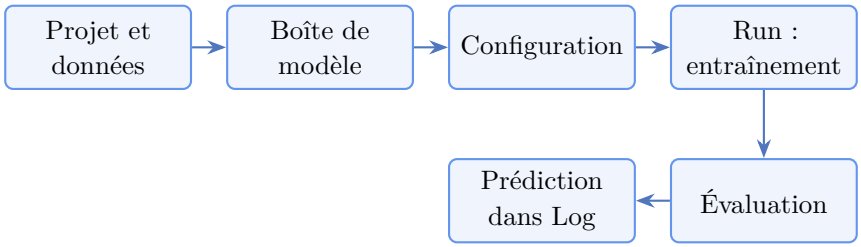
4.1 Les algorithmes disponibles

Algorithme	**Principe**	**Paramètres réglables (défaut)**	**Points forts**
Linear	Droite (ou hyperplan) des moindres carrés	Aucun	Simple, coefficients interprétables
Lasso	Régression linéaire pénalisée par la somme des |coefficients|	alpha (1,0)	Met à zéro les features inutiles
Kernel ridge (KR)	Régression ridge dans un espace de noyau	alpha (1,0)	Stable avec des features corrélées
Support Vector Regression (SVR)	Tube de tolérance autour de la fonction, noyau gaussien (RBF)	C (100), gamma (0,1)	Relations non linéaires, peu d'expériences
Random Forest (RF)	Moyenne de nombreux arbres construits sur des échantillons tirés au hasard	nombre d'arbres (100), random state (0)	Robuste, importance des features
Generalized Boosted Regression Modeling (GBM)	Arbres ajoutés un à un, chacun corrigeant les erreurs des précédents	nombre d'arbres (500), profondeur (5), learning rate (0,5), fonction de perte	Très précis sur des relations complexes
Decision Tree (DT)	Découpages successifs des données selon des seuils	profondeur max (20), random state (0)	Lisible sous forme de règles
Gaussian process (GP)	Loi de probabilité sur les fonctions, noyau produit scalaire + bruit blanc	random state (0)	Fournit une incertitude sur la prédiction

Remarque pédagogique

Un modèle trop simple sous-apprend : il manque la tendance. Un modèle trop souple sur-apprend : il reproduit le bruit des données d'entraînement et prédit mal les nouvelles. Les paramètres alpha, C, la profondeur ou le nombre d'arbres règlent cet équilibre.

4.2 Vue d'ensemble du parcours



Chaque étape est détaillée ci-dessous. Plusieurs modèles peuvent suivre ce parcours en parallèle dans le même projet, pour être comparés.

4.3 Étape 1 : préparer le projet et les données

1. **New** : créer le projet.
2. **Import data** : charger le tableau.
3. **Edit data** : nettoyer, filtrer et imputer les manquants (section 3.1).

4.4 Étape 2 : créer une boîte de modèle

1. Cliquer sur **Model**, puis sur le bouton *Nouveau modèle* de la barre gauche.
2. Donner un nom (par exemple « RF température ») et, si on le souhaite, une couleur.
3. Une boîte apparaît dans le panneau. On peut la déplacer à la souris.

La boîte affiche le nom du modèle et son état : configuré, puis entraîné. Une fois le modèle configuré, l'algorithme choisi s'affiche en haut de la boîte (son sigle, par exemple « GBM », si le nom est trop long).

4.5 Étape 3 : configurer le modèle

Sélectionner la boîte, puis cliquer sur *Configurer* (ou double-cliquer sur la boîte). Choisir l'algorithme dans la liste, puis renseigner les champs.

Champ	Rôle	Conseil
Target column	Variable à prédire	Une seule colonne numérique
Calculation method	TrainTestSplit data ou Cross-validation	Voir section 4.6
Test size / Split size	Part de test (TrainTestSplit) ou nombre de plis K (Cross-validation)	0,2 et $K = 5$ à 10 sont des choix courants
Feature columns	Variables explicatives candidates	Exclure la cible et les identifiants
Recoding method	None, Disjunctive ou All-disjunctive	Voir ci-dessous
Recoding feature columns	Colonnes à recoder (mode Disjunctive)	Les colonnes qualitatives
Paramètres de l'algorithme	alpha, C, gamma, profondeur…	Garder les valeurs par défaut pour un premier essai

Recodage des variables qualitatives. Un algorithme ne manipule que des nombres. Une colonne qualitative à m modalités est donc transformée en $m-1$ indicatrices 0/1. La modalité la plus fréquente sert de référence et n'a pas d'indicatrice. Les colonnes qualitatives sont toujours recodées, même avec le mode None.

Cliquer enfin sur **Save configure**. La configuration est mémorisée et sera exécutée à chaque **Run**, sans rouvrir ce panneau.



Figure 6 – Boutons de la configuration d'un modèle et de ses résultats.

4.6 Étape 4 : entraîner avec Run

Run entraîne tous les modèles configurés du projet. Le panneau **Model** reste affiché, avec l'encadré de progression. Le bouton *Arrêt* ⏹ interrompt l'exécution : les modèles déjà entraînés conservent leurs résultats.

Dans les deux méthodes, les données sont d'abord séparées en une partie d'entraînement et une partie de test, avec une graine fixe pour que le résultat soit reproductible.

Méthode	**Entraînement**	**Test**	**Ce qui est optimisé**
TrainTestSplit data	1− Test size (80 % par défaut)	Test size (20 %)	Sélection des features
Cross-validation	80 %	20 %	Hyperparamètres par validation croisée à K plis, puis sélection des features

Validation croisée à K plis. La partie d'entraînement est découpée en K blocs. Le modèle est entraîné K fois, chaque fois sur $K-1$ blocs, et évalué sur le bloc restant. Les hyperparamètres retenus minimisent l'erreur moyenne sur ces K essais. Les 20 % de test ne servent qu'à l'évaluation finale.

Sélection des features. Une sélection séquentielle ascendante part d'un modèle sans feature. Elle ajoute à chaque pas la feature qui améliore le plus le score, puis garde le meilleur sous-ensemble.

4.7 Étape 5 : évaluer le modèle

Deux indicateurs sont calculés sur les données de test, où y_i est la valeur mesurée et $\hat{y}_i$ la valeur prédite :

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} \qquad \text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{3}$$

Indicateur	**Lecture**
R^2 proche de 1	Le modèle explique presque toute la variabilité de la cible
R^2 proche de 0	Pas mieux que prédire la moyenne
R^2 négatif	Moins bon que la moyenne : modèle à revoir
MSE	Erreur quadratique moyenne, dans l'unité de la cible au carré ; plus elle est faible, mieux c'est

Les résultats s'affichent dans **Log**, case **Model plots** : un onglet par modèle.

— **Graphique prédit / mesuré** : un point par expérience de test, valeur mesurée en abscisse et prédite en ordonnée. Plus les points sont proches de la diagonale, meilleur est le modèle. La case **Train data** ajoute les points d'entraînement.

— **Detail of model** : algorithme, paramètres, cible, meilleures features retenues, coefficients (Linear, Lasso) ou importances (RF, GBM, DT), R^2, MSE et nombre d'observations d'entraînement et de test.

Remarque pédagogique

Un R^2 d'entraînement très supérieur au R^2 de test signale un sur-apprentissage. Afficher les points d'entraînement avec **Train data** permet de le voir directement.

4.8 Étape 6 : prédire de nouvelles expériences

Le panneau **Log** utilise automatiquement le meilleur modèle entraîné, celui qui a le R^2 de test le plus élevé.



Figure 7 – Boutons du panneau **Log** (prédiction).

1. **Import data** : charger un tableau contenant les mêmes features que celles du modèle.
2. Si besoin, filtrer (Parameter 1 à 4) et imputer les manquants, comme dans **Edit data**.
3. **Show all** : afficher les données avec la colonne de prédiction ajoutée.
4. **Overview stat** et **Detail of model** : contrôler les données et rappeler le modèle utilisé.
5. **Export pred** : exporter le tableau avec les prédictions.

Les colonnes qualitatives sont recodées exactement comme à l'entraînement. S'il manque une feature du modèle, la prédiction est refusée avec un message explicite.

Remarque pédagogique

Un modèle ne prédit de façon fiable que dans le domaine couvert par ses données d'entraînement. Prédire à une température bien au-delà de la plus haute température mesurée est une extrapolation, à interpréter avec prudence.

5. Optimisation

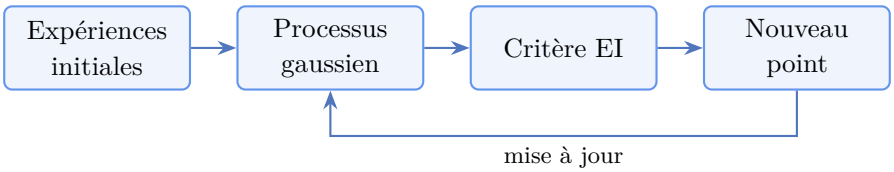
L'optimisation cherche les valeurs des features qui maximisent la cible, par exemple les conditions opératoires qui donnent le meilleur rendement. SmartDigiCat utilise l'optimisation bayésienne, adaptée aux situations où chaque expérience coûte cher et où l'on dispose de peu de points.

5.1 Principe de l'optimisation bayésienne

L'idée est d'alterner deux gestes :

1. **Modéliser** la réponse inconnue $f(\mathbf{x})$ par un processus gaussien, construit à partir des expériences déjà réalisées. Ce modèle fournit en tout point une prédiction et une incertitude.
2. **Choisir** le point suivant qui offre le meilleur compromis entre exploitation (là où la prédiction est haute) et exploration (là où l'incertitude est grande).

Le nouveau point est ajouté aux données, le modèle est mis à jour, et le cycle recommence.



Le processus gaussien. On suppose que les valeurs de f en n points suivent une loi normale multivariée. La corrélation entre deux points décroît avec leur distance, selon un noyau de Matérn :

$$k_\nu(d) = \frac{2^{1-\nu}}{\Gamma(\nu)} \left(\sqrt{2\nu}\, d\right)^\nu K_\nu\left(\sqrt{2\nu}\, d\right), \qquad d = \sqrt{\sum_{j=1}^{p} \left(\frac{x_j - x'_j}{\theta_j}\right)^2} \tag{4}$$

Paramètre	Sens	Estimation dans SmartDigiCat
θ_j (portée)	Distance sur laquelle la feature j influence la réponse	Tiré par Monte-Carlo par chaînes de Markov
ν (régularité)	Degré de lissage de la fonction	Tiré par Monte-Carlo par chaînes de Markov
σ^2 (variance)	Amplitude des variations de la réponse	Loi a posteriori calculée analytiquement

K_ν désigne la fonction de Bessel modifiée de seconde espèce. Les paramètres ne sont pas fixés une fois pour toutes : ils sont tirés selon leur loi a posteriori par un algorithme de Metropolis-Hastings. Cette approche entièrement bayésienne propage l'incertitude sur les paramètres jusqu'au choix du point suivant.

Le critère d'amélioration espérée (EI). Soit f^* la meilleure valeur observée, $\mu(\mathbf{x})$ et $s(\mathbf{x})$ la moyenne et l'écart-type prédits en $\mathbf{x}$. Le critère vaut :

$$\mathrm{EI}(\mathbf{x}) = (\mu(\mathbf{x}) - f^*)\,\Phi(z) + s(\mathbf{x})\,\varphi(z), \qquad z = \frac{\mu(\mathbf{x}) - f^*}{s(\mathbf{x})} \tag{5}$$

Φ et φ sont la fonction de répartition et la densité de la loi normale centrée réduite. Le premier terme récompense une prédiction élevée, le second une forte incertitude. Le point proposé est celui qui maximise EI.

Remarque pédagogique

Chercher seulement le maximum de la prédiction enfermerait l'algorithme autour du meilleur point connu. Le terme d'incertitude le pousse aussi vers les régions peu explorées, où se cache

peut-être un meilleur optimum.

5.2 Ouvrir le panneau

Plots → Optimization. La zone de gauche affiche le graphique ; la zone de droite contient trois groupes de réglages : Imput, Output et Export.



Figure 8 – Boutons du panneau d'optimisation.

5.3 Définir le problème (Optimization settings)

Champ	Rôle	Exemple
Optimization method	FBA, EGO quanti ou EGO mixt	FBA
Target column	Grandeur à maximiser	Rendement
Target Min / Max	Plage plausible de la cible	0 et 100 (%)
Feature columns	Features à faire varier	Température, pression
Feature Min / Max	Domaine de recherche de chaque feature, séparé par des virgules	200,1 et 400,10
N	Nombre d'itérations, soit de points proposés	10
seed	Graine du générateur aléatoire	0

Les contrôles suivants sont faits avant le calcul : Min $<$ Max pour la cible et chaque feature, $N \geq 2$, et un Min et un Max par feature. Un message indique quand tous les paramètres sont valides ; on clique alors sur **Save**.

Dans la version 1.0, le choix de la méthode est obligatoire, mais les trois options exécutent le même algorithme bayésien décrit ci-dessus.

Remarque pédagogique

La graine rend le résultat reproductible : mêmes données, mêmes paramètres et même graine donnent les mêmes points. Changer la graine permet de vérifier que les points proposés ne dépendent pas du hasard.

5.4 Lancer et suivre l'optimisation

1. Si besoin, **Import data** (groupe Imput) charge un tableau dédié ; sinon, les données du projet sont utilisées.
2. Cliquer sur **Run optim**. La zone du graphique est vidée et l'encadré de progression s'y affiche.
3. À la fin, le panneau est rafraîchi et le graphique apparaît. Le bouton *Arrêt* ⏹ interrompt le calcul ; le résultat précédent est alors conservé.

Les N points sont proposés l'un après l'autre : chacun tient compte de tous les précédents.

5.5 Lire le résultat

Les cases du groupe Output composent le graphique.

Case	Élément tracé
Given data points	Expériences initiales (noir)
Optimized points	Points proposés par l'optimisation (rouge)
Curve estimated	Réponse estimée par un processus gaussien de Matérn (une seule feature)
Error (95%)	Bande de confiance à 95 % autour de la courbe
Optimized table	Tableau des points proposés ; **with given points** y ajoute les expériences initiales

Line width, **Point size** et le curseur de zoom règlent l'aspect. La liste **X axis** choisit la feature portée en abscisse ; avec plusieurs features, le graphique est une projection sur cette feature.

Remarque pédagogique

La bande à 95 % est étroite près des expériences et s'élargit loin d'elles. Un point proposé dans une zone large est un point d'exploration : il apprend beaucoup au modèle, même s'il ne donne pas forcément le meilleur rendement.

5.6 Exporter et exploiter les points

— **Save plot** enregistre le graphique (PNG, PDF ou JPEG).

— **Save points** exporte le tableau des points en Excel ou CSV.

Les valeurs de la cible associées aux points proposés sont des estimations du modèle, pas des mesures. La démarche complète consiste à réaliser ces expériences au laboratoire, à ajouter les résultats mesurés au tableau, puis à relancer l'optimisation. Chaque cycle affine la connaissance de la réponse autour de l'optimum.